

# La régression Bêta

Une alternative intéressante pour modéliser des proportions

Maxime Lacroix

28 septembre 2018

# Mise en contexte

# Contexte

- Régression sur une variable réponse tenue entre  $(0,1)$
- Par exemple, un taux ou une proportion
- Régression linéaire “classique” à éviter

# Première solution : transformation logit

## Première transformation possible

$$\tilde{y} = \log\left(\frac{y}{1-y}\right) \quad (1)$$

- Avantage :
  - Les données ne sont plus bornées, la régression linéaire est envisageable
- Désavantages :
  - Interprétation différente
  - Fort potentiel d'hétéroscédasticité
  - Les données sont souvent asymétrique → problèmes pour les tests d'hypothèses et les intervalles de confiance.

## Solution : Régression Bêta

# Brève présentation

- Présentée pour la première fois en 2004 par Ferrari et Cribari-Neto
- Intérêt majeur :
  - La densité bêta prend différentes formes dépendamment des paramètres
  - Densité généralement hétéroscédastique
  - Interprétation semblable à la régression logistique

METTRE DES GRAPHIQUES QUI PROUVENT LE POINT 2

# Présentation mathématique

## Densité d'une loi bêta

$$f_Y(y) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y^{\alpha-1} (1-y)^{\beta-1} \quad (2)$$

De l'équation 2, Ferrari et Cribari-Neto ont proposé une nouvelle paramétrisation, en posant :

- $\mu = \frac{\alpha}{\alpha + \beta}$
- $\phi = \alpha + \beta$

# Nouvelle paramétrisation

On obtient :

Densité sous la nouvelle paramétrisation

$$f(k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (3)$$



##	speed	dist
##	Min. : 4.0	Min. : 2.00
##	1st Qu.:12.0	1st Qu.: 26.00
##	Median :15.0	Median : 36.00
##	Mean :15.4	Mean : 42.98
##	3rd Qu.:19.0	3rd Qu.: 56.00
##	Max. :25.0	Max. :120.00